

# KOMPARATIVNA ANALIZA ARHITEKTURA DUBOKOG UČENJA ZA DETEKCIJU MALARIJE: CNN VS. FOUNDATION MODELI

**Predmet:** Metode istraživanja i eksploatacije podataka

**Projekat:** Klasifikacija biomedicinskih slika

**Student:** Branko Milošević IT 26-2020

**Asistent:** Nikola Jovišić

## 1. UVOD

Ovaj rad istražuje primenu savremenih metoda računarskog vida (*Computer Vision*) za automatizovanu dijagnostiku malarije analizom mikroskopskih snimaka tankih krvnih razmaza. Cilj istraživanja je poređenje performansi namenski kreirane Konvolutivne neuronske mreže (Custom CNN) i primene *Transfer Learning* paradigme korišćenjem *State-of-the-Art* (SOTA) modela **DINOv2** (Vision Transformer).

Poseban fokus rada je na "**Data-Efficient**" učenju. Eksperimenti su pokazali da DINOv2 model, koristeći samo 10% dostupnih podataka za trening, postiže superiorne rezultate (AUC ROC > 0.99) u odnosu na klasične pristupe, demonstrirajući visoku sposobnost generalizacije i kliničku primenljivost.

Malarija predstavlja jedan od vodećih globalnih zdravstvenih izazova. Standardna metoda dijagnostike podrazumeva manuelni pregled krvnih razmaza pod mikroskopom, što je proces koji je vremenski zahtevan i zavisi od ekspertize tehničara. Automatizacija ovog procesa primenom mašinskog učenja može drastično ubrzati dijagnostiku i smanjiti ljudsku grešku.

U ovom projektu fokusiramo se na problem **binarne klasifikacije** ćelija na dve kategorije:

1. **Parasitized:** Ćelije inficirane parazitom *Plasmodium*.
2. **Uninfected:** Zdrave ćelije.

## 2. SKUPOVI PODATAKA (DATASET)


Korišćen je javno dostupan **NIH Malaria Dataset** (dostupan kroz *TensorFlow Datasets* repozitorijum). Originalni skup sadrži ukupno 27.558 slika, balansiranih između dve klase.

### 2.1. Preprocesiranje i Augmentacija


Slike u originalnom setu su različitih rezolucija. Za potrebe treninga neuronskih mreža, izvršena je standardizacija:

- **Rezolucija:** Sve slike su skalirane na  $224 \times 224$  piksela (standard za Transformer modele).
- **Normalizacija:** Vrednosti piksela su normalizovane korišćenjem *ImageNet* statistike (mean/std), što je neophodno za DINOv2 arhitekturu.

### 2.2. Vizuelizacija uzoraka



(a) Parasitized cells.



(b) Uninfected cells.

Na slici su prikazani reprezentativni primeri iz skupa podataka. Jasno se uočavaju morfološke razlike – prisustvo ljubičastih mrlja unutar citoplazme kod zaraženih ćelija.

Kao deo eksperimenta robusnosti (*Robustness check*), za trening DINOv2 modela izdvojen je podskup od **samo 10% podataka** (približno 2.750 slika), dok je validacija vršena na odvojenom skupu kako bi se osigurala objektivnost metrika.

## 3. METODOLOGIJA I ARHITEKTURE MODELA

U ovom istraživanju implementirana su i upoređena dva različita pristupa dubokom učenju.

### 3.1. Pristup 1: Custom CNN (Treniranje od nule)

Prvi model je konvolutivna neuronska mreža (CNN) dizajnirana specifično za ovaj zadatak. Mreža se sastoji od tri konvolutivna bloka. Svaki blok sadrži:

- Conv2D sloj za ekstrakciju vizuelnih karakteristika (ivice, teksture).
- MaxPooling2D sloj za smanjenje dimenzionalnosti (*downsampling*).

- ReLU aktivacionu funkciju za uvođenje nelinearnosti.

Nakon ekstrakcije karakteristika, vektor se "pegla" (*Flatten*) i prolazi kroz potpuno povezane slojeve (*Dense*). Ključna komponenta ove arhitekture je **Dropout sloj (0.5)**, koji je implementiran radi sprečavanja preprilagođavanja (*overfitting*).

### 3.2. Pristup 2: DINOv2 (Transfer Learning sa Transformerima)

Drugi, napredniji pristup, zasniva se na korišćenju **Foundation modela**. Odabran je **DINOv2** (*small* varijanta), model razvijen od strane kompanije Meta AI.

**Zašto DINOv2?** Za razliku od standardnih modela koji uče na obeleženim slikama (Supervised Learning), DINOv2 koristi **samonadzirano učenje** (*Self-Supervised Learning*) na stotinama miliona slika. To mu omogućava da razume semantiku slike mnogo bolje od klasičnih CNN mreža.

**Implementacija:** Koristili smo *Transfer Learning* tehniku:

1. **Zamrzavanje (Freezing):** "Telo" modela (*Backbone*) je zamrznuto. Težine se ne menjaju tokom treninga, čime drastično štedimo resurse.
2. **Klasifikaciona Glava (Head):** Na izlaz DINOv2 modela dodali smo jednostavan linearni klasifikator koji uči da mapira bogate reprezentacije koje daje DINOv2 u naše dve klase (Malaria: Da/Ne).

Ovaj pristup omogućava treniranje modela za samo nekoliko minuta, čak i na malom broju slika.

## 4. REZULTATI I DISKUSIJA

Evaluacija modela izvršena je na validacionom skupu podataka koji modeli nisu "videli" tokom treninga. Fokus evaluacije je bio na metrikama koje su klinički relevantne.

### 4.1. Kvantitativna analiza

U tabeli 1 prikazani su rezultati nakon finalne epohe treninga.

**Tabela 1: Poređenje performansi modela**

Metrika	Custom CNN (Baseline)	DINOv2
Trening podaci	100% (27.500 slika)	10% (2750 slika)
Broj epoha	10	3
Accuracy	95.6%	~96.5%
AUC ROC	0.978	0.9929
F1 Score	0.945	0.9599
Vreme Treninga	~20 min	~1 min (na GPU)

## 4.2. Analiza kliničkih metrika

Za medicinske primene, sama tačnost (*Accuracy*) nije dovoljna. Najvažnije metrike su:


- **Osetljivost (Sensitivity/Recall):** Sposobnost modela da detektuje bolesnog pacijenta. DINOv2 je pokazao visoku osetljivost, što znači da je broj lažno negativnih rezultata (najopasnija greška) minimalan.
- **AUC (Area Under Curve):** Skor od **0.9929** ukazuje na to da model ima skoro savršenu sposobnost razdvajanja klasa. Verovatnoća da će model rangirati slučajno odabran pozitivan uzorak više od negativnog je preko 99%.

Tabela 2: Detaljne metrike DINOv2 modela

Metrika	Vrednost	Interpretacija
Validation Loss	0.1239	Veoma niska greška predikcije
Specificity	> 0.95	Nizak broj lažnih alarma
Konvergencija	Veoma brza	Model je naučio problem već u prvoj epohi

## 5. GRAFIČKA EVALUACIJA (ROC i PR Krive)

Vizuelna potvrda kvaliteta modela data je kroz ROC (*Receiver Operating Characteristic*) i *Precision-Recall* krive.



### Analiza grafika:

- **ROC kriva:** Kriva se "lepi" za gornji levi ugao, što je idealan scenario. To znači da model može postići *True Positive Rate* (stopu pogodaka) od blizu 100% uz minimalan *False Positive Rate* (lažne uzbune).
- **Precision-Recall:** Visoka površina ispod ove krive potvrđuje da je model stabilan čak i ako podaci nisu savršeno balansirani.

## 6. ZAKLJUČAK I BUDUĆI RAD

Ovaj projekat je demonstrirao da su moderni **Foundation modeli (kao što je DINOv2)** superiorni u odnosu na tradicionalne metode dubokog učenja u domenu medicinske analize slike.

### Ključni nalazi:

1. **Efikasnost podataka:** DINOv2 je postigao vrhunske rezultate ( $AUC > 0.99$ ) koristeći **10 puta manje podataka** od CNN modela.
2. **Modularnost:** Kod je uspešno refaktorisao u modularne Python skripte, omogućavajući lako održavanje i reprodukciju eksperimenta.
3. **Resursi:** Korišćenjem *Transfer Learning-a*, drastično je smanjeno vreme i energija potrebna za treniranje modela.